

令和4年度 修士論文

推定値の不確実性を考慮した状態と
報酬に基づく深層強化学習型コンピュータ適応型
テストの項目選択

電気通信大学 情報理工学域

情報数理工学科

学籍番号 2311237

柴沼 巖

指導教員：宇都雅輝 准教授

2026年9月29日

コンピュータ適応型テストでは，受験者の能力推定値に応じて次に出題する項目を逐次的に選択する．近年，項目選択を逐次決定問題として定式化し，深層Q学習により選択方策を学習する方法が提案され，最大情報量法を上回る推定精度が報告されている．しかし，この方法には，Q関数の全パラメータに課される非負制約が価値関数の形を制限すること，能力推定値だけを状態とするため状態の遷移が一意に定まらないこと，及び報酬が最大情報量法の項目選択規準と一致するため推定値の不確実性を報酬に反映できないことという問題がある．本論文では，最尤推定値，テストの進行度，事後分散からなる状態と，事後精度の増分という推定値の不確実性を考慮した報酬を用い，パラメータに制約を課さない深層Q学習型の項目選択法を提案する．2パラメータロジスティックモデルに基づくシミュレーション実験により，提案手法がテスト序盤で最大情報量法を上回り，事後分布に基づく解析的な項目選択規則と同等の精度を，候補項目ごとの期待値計算を学習したQ関数で置き換えて達成すること，既存手法の劣化の決定的な要因が非負制約と学習設定であること，及びデータ生成モデルが推測を含む場合には実際の反応から学習した提案手法が解析的な項目選択規則を小さいながら一貫して上回ることを示す．

目次

第1章	はじめに	1
第2章	タスク設定	3
2.1	項目反応モデル	3
2.2	能力推定	4
2.3	事後分布	5
第3章	情報量に基づく項目選択	6
第4章	強化学習に基づく項目選択	8
4.1	マルコフ決定過程としての定式化	8
4.2	深層Q学習	8
4.3	既存手法の問題点	9
第5章	提案手法	11
5.1	推定値の不確実性を考慮した状態	11
5.2	推定値の不確実性を考慮した報酬	11
5.3	制約と学習	12
5.4	実際の反応からの学習と推定モデルへの依存	13
第6章	シミュレーション実験	15
6.1	実験設定	15

第7章	主結果	18
7.1	報酬関数と割引率の感度分析	20
7.2	状態表現の比較	22
7.3	既存手法から提案手法への要因分解	23
7.4	選択される項目の分析	25
7.5	推定モデルとデータ生成モデルが異なる場合の比較	27
7.6	考察	30
7.7	まとめ	31
参考文献		33

第1章

はじめに

近年，受験者ごとに出題する項目を適応的に変えるコンピュータ適応型テスト (computerized adaptive testing; CAT) が，資格試験や学力調査を含む多様な場面で利用されている [1]．CATとは，項目反応理論に基づいて受験者の能力を逐次的に推定し，その推定値に応じて次の項目を選択する方法であり，項目固定形式のテストより少ない項目数で同等の測定精度を達成できるという利点を有する [2, 1]．

CATの中核は項目選択規則である．最も広く用いられる項目選択規則は，現在の能力推定値においてフィッシャー情報量を最大にする項目を選ぶ最大情報量法 (maximum Fisher information; MFI) である [2]．しかし，テスト序盤の能力推定値は真の能力から大きく離れ得るため，その推定値で情報量を最大化しても真の能力において情報量の高い項目が選ばれるとは限らないことが指摘されてきた [3]．この問題を解決する項目選択規則として，反応履歴の尤度で重み付けした情報量を用いる方法 [4]や，事後分布で重み付けした情報量を用いる方法 [5]が提案されている．

他方で，項目選択を逐次決定問題とみなし，強化学習により選択方策を獲得する方法が近年提案されている [6, 7]．特にWangらは，能力推定値を状態，項目を行動，選択した項目のフィッシャー情報量を報酬とするマルコフ決定過程を定義し，深層Q学習 (deep Q-network; DQN) [8]により方策を学習する方法を提案し，シミュレーション実験においてMFIを含む既存の項目選択規則を上回る推定精度を報告している [7]．

しかし、この方法には次の問題がある。(1) Q関数を近似するニューラルネットワークの全パラメータに非負制約を課すため、各項目の価値が能力推定値の単調非減少な関数に制限され、困難度が推定値に近い項目ほど価値が高いという構造を表現できない。(2) 状態を能力推定値だけとするため、同じ状態と行動から異なる推定値の更新が生じ、Q関数が定義する将来価値が一意に定まらない。(3) 報酬設計がMFIによる項目選択規準と一致するため、MFIと同様に推定値の不確実性を報酬に反映できない。

以上の問題を解決するために、本研究では、推定値の不確実性を考慮した状態と報酬に基づく深層Q学習型の項目選択法を提案する。提案手法の利点は次のとおりである。(1) パラメータに制約を課さないため、価値関数が困難度と推定値の対応を表現できる。(2) 最尤推定値、テストの進行度、事後分散からなる状態を用いるため、同じ推定値でも不確実性が異なる状態を区別できる。(3) 報酬を事後精度の増分とするため、推定値の不確実性を反映した規準を学習でき、割引率を1とすると収益がテスト終了時の事後精度に一致する。

本論文では、シミュレーション実験を通して、能力推定に利用したモデルが真のデータ生成モデルと一致する場合の提案手法の精度を、事後分布に基づく解析的な項目選択規則との比較を含めて評価する。さらに、報酬、割引率、状態表現のそれぞれについて感度分析を行い、既存手法との差分についての要因分解も行うことで、精度を左右する要素を明らかにする。さらに、能力推定に利用したモデルと真のデータ生成モデルとの乖離がある場合の精度についても評価を行う。

第2章

タスク設定

2.1 項目反応モデル

項目バンクは I 個の二値項目からなる．本研究では，項目 $i \in \{1, \dots, I\}$ への受験者 $j \in \{1, \dots, J\}$ の正答確率が，項目反応理論の一つである，2パラメータロジスティックモデル（two-parameter logistic model; 2PLM）に従うと仮定する．2PLMに基づく正答確率は次式で定義される．

$$P_i(\theta_j) = \frac{1}{1 + \exp\{-a_i(\theta_j - b_i)\}} \quad (2.1)$$

ここで， θ_j は受験者 j の能力， a_i は項目 i の識別力， b_i は項目 i の困難度を表す．本論文では，能力推定と項目選択に利用するこの項目反応モデルを推定モデルと呼ぶ．受験者の反応を実際に生成する過程であるデータ生成モデルは推定モデルと一致するとは限らず，両者が異なる場合を5.4と7.5で扱う．

2PLMに従うと，項目 i が能力 θ においてもつフィッシャー情報量は次式で与えられる．

$$\mathcal{I}_i(\theta) = a_i^2 P_i(\theta) \{1 - P_i(\theta)\} \quad (2.2)$$

テスト長を L とし，ステップ $t \in \{1, \dots, L\}$ において受験者 j へ出題する項目を i_{jt} ，その反応を $u_{jt} \in \{0, 1\}$ と書く．ステップ t までの反応履歴を $h_{jt} = \{(i_{js}, u_{js})\}_{s=1}^t$ ，出題した項目の集合を S_{jt} とし， $h_{j0} = \emptyset$ ， $S_{j0} = \emptyset$ とする．ステップ t で選択可能な項目

の集合は $B_{jt} = \{1, \dots, I\} \setminus S_{j,t-1}$ である。ステップ t の終了時点における能力推定値を $\hat{\theta}_{jt}$ と書き、テスト開始前の初期値を $\hat{\theta}_{j0}$ と書く。

2.2 能力推定

ステップ t の終了時点で、反応履歴 h_{jt} から能力を推定する。推定法は最尤法とし、探索範囲を有界な閉区間 $[\theta_{\min}, \theta_{\max}]$ に限定する。対数尤度は次式である。

$$\ell_{jt}(\theta) = \sum_{s=1}^t \left[u_{js} \log P_{i_{js}}(\theta) + (1 - u_{js}) \log \{1 - P_{i_{js}}(\theta)\} \right] \quad (2.3)$$

2PLMの対数尤度は θ について凹関数であり、その導関数

$$\ell'_{jt}(\theta) = \sum_{s=1}^t a_{i_{js}} \{u_{js} - P_{i_{js}}(\theta)\} \quad (2.4)$$

は θ について狭義単調減少である。したがって、区間内の最尤推定値は、区間の中点で ℓ'_{jt} を評価し、正なら下端を、非正なら上端を中点へ更新する二分法で求められる。

全ての反応が正答または誤答である場合、最尤推定値は有限に存在しない。この場合は先行研究 [7] と同じく Dodd の規則 [9] に従い、前ステップの推定値からバンクの最大困難度または最小困難度へ向けて半分だけ移動させる。すなわち、 $b_{\max} = \max_i b_i$, $b_{\min} = \min_i b_i$ として、

$$\hat{\theta}_{jt} = \begin{cases} \hat{\theta}_{j,t-1} + \frac{b_{\max} - \hat{\theta}_{j,t-1}}{2} & (\text{全問正答}) \\ \hat{\theta}_{j,t-1} - \frac{\hat{\theta}_{j,t-1} - b_{\min}}{2} & (\text{全問誤答}) \\ \arg \max_{\theta \in [\theta_{\min}, \theta_{\max}]} \ell_{jt}(\theta) & (\text{それ以外}) \end{cases} \quad (2.5)$$

とする。式(2.5)の推定量は、本論文で比較する全ての項目選択規則で共通に用いる。したがって、項目選択規則間の差は項目の選び方だけに帰着する。また、受験者 j の L 個の反応全てから式(2.5)で求めた推定値 $\tilde{\theta}_j = \hat{\theta}_{jL}$ を、以下では参照能力値と呼ぶ。参

照能力値は，テスト終了後に反応記録だけから計算できる量であり，7.1の報酬の比較で用いる．

2.3 事後分布

後述する項目選択規則のいくつかは，反応履歴を与えたときの能力の事後分布を用いる．事前分布を標準正規分布 $N(0, 1)$ とし， $[\theta_{\min}, \theta_{\max}]$ 上の等間隔な G 点の格子 $\{\theta_g\}$ で事後分布を近似する．格子点の事後重みは

$$w_{jt}(\theta_g) = \frac{\exp\{\ell_{jt}(\theta_g)\} \phi(\theta_g)}{\sum_{g'} \exp\{\ell_{jt}(\theta_{g'})\} \phi(\theta_{g'})} \quad (2.6)$$

であり， ϕ は標準正規密度である．事後平均 $\mu_{jt} = \sum_g w_{jt}(\theta_g) \theta_g$ ，事後分散 $V_{jt} = \sum_g w_{jt}(\theta_g) (\theta_g - \mu_{jt})^2$ と書く． $t = 0$ では w_{j0} は事前分布の格子近似であり， V_{j0} は1に近い値をとる．また，事前分布を用いない尤度の正規化重みを $\tilde{w}_{jt}(\theta_g) = \exp\{\ell_{jt}(\theta_g)\} / \sum_{g'} \exp\{\ell_{jt}(\theta_{g'})\}$ と書く．

第3章

情報量に基づく項目選択

MFIは、ステップ t において、前ステップの能力推定値における情報量が最大の未出題項目を選ぶ項目選択規則である [2].

$$i_{jt} = \arg \max_{i \in \mathcal{B}_{jt}} \mathcal{I}_i(\hat{\theta}_{j,t-1}) \quad (3.1)$$

MFIは1ステップ先の情報量だけを最大化する局所的な項目選択規則であり、 $\hat{\theta}_{j,t-1}$ が真の能力から離れているテスト序盤には、真の能力において情報量の高い項目を選ぶとは限らない.

推定値の不確実性を考慮する項目選択規則として、情報量を能力の分布で平均する項目選択規則が提案されている. 尤度重み付き情報量法 (Fisher information weighted by likelihood; FIWL) [4]は、事前分布を置かず、反応履歴の尤度を重みとする.

$$i_{jt} = \arg \max_{i \in \mathcal{B}_{jt}} \sum_g \tilde{w}_{j,t-1}(\theta_g) \mathcal{I}_i(\theta_g) \quad (3.2)$$

事後重み付き情報量法 (maximum posterior-weighted information; MPWI) [5]は、式(2.6)の事後重みを用いる.

$$i_{jt} = \arg \max_{i \in \mathcal{B}_{jt}} \sum_g w_{j,t-1}(\theta_g) \mathcal{I}_i(\theta_g) \quad (3.3)$$

反応がない $t = 1$ では、FIWLの重みは格子上で一様、MPWIの重みは事前分布である. 更に、1ステップ先の事後分散の期待値を最小にする最小期待事後分散法 (minimum

expected posterior variance; MEPV) [10, 5]は, 候補項目 i への反応 $u \in \{0, 1\}$ の予測確率 $\pi_i(u) = \sum_g w_{j,t-1}(\theta_g) P_i(\theta_g)^u \{1 - P_i(\theta_g)\}^{1-u}$ と, 反応 u を得た後の事後分散 $V_{jt}(i, u)$ を用いて

$$i_{jt} = \arg \min_{i \in \mathcal{B}_{jt}} \sum_{u \in \{0,1\}} \pi_i(u) V_{jt}(i, u) \quad (3.4)$$

とする項目選択規則である. MEPVは候補項目ごとに二通りの反応に対する事後分布のモーメントを計算する必要がある, 計算量が最も大きい.

第4章

強化学習に基づく項目選択

4.1 マルコフ決定過程としての定式化

Wangら [7]は，受験者一人のテストを一つのエピソードとし，ステップ t の状態を前ステップの能力推定値 $s_{jt} = \hat{\theta}_{j,t-1}$ ，行動を出題する項目 $i_{jt} \in \mathcal{B}_{jt}$ ，報酬を選択した項目が選択時の推定値においてもつフィッシャー情報量

$$r_{jt}^{(\text{prev})} = \mathcal{I}_{i_{jt}}(\hat{\theta}_{j,t-1}) \quad (4.1)$$

とするマルコフ決定過程を定義した．エピソードはステップ L の反応を得た時点で終了する．割引率を $\gamma \in [0, 1]$ とし，方策 π の下での行動価値関数を $Q^\pi(s, i) = E_\pi[\sum_{k=0}^{L-t} \gamma^k r_{j,t+k} \mid s_{jt} = s, i_{jt} = i]$ と定める．

4.2 深層Q学習

行動価値関数を，状態を入力とし各項目の価値を並べた I 次元ベクトルを出力する全結合ニューラルネットワーク $Q(s, \cdot; \mathbf{w})$ で近似する．ネットワークは隠れ層2層からなり，活性化関数をReLUとする．

$$Q(s, \cdot; \mathbf{w}) = W_3 \phi(W_2 \phi(W_1 s + \mathbf{c}_1) + \mathbf{c}_2) + \mathbf{c}_3 \quad (4.2)$$

ここで, $\phi(x) = \max(x, 0)$ を要素ごとに適用し, $W_1 \in \mathbb{R}^{H_1 \times d}$, $W_2 \in \mathbb{R}^{H_2 \times H_1}$, $W_3 \in \mathbb{R}^{I \times H_2}$, $\mathbf{c}_1 \in \mathbb{R}^{H_1}$, $\mathbf{c}_2 \in \mathbb{R}^{H_2}$, $\mathbf{c}_3 \in \mathbb{R}^I$ であり, d は状態の次元, $\mathbf{w}$ は全パラメータをまとめたものである.

学習は経験再生と目標ネットワークを用いるDQN [8]に従う. 学習用の受験者の能力を $N(0, 1)$ から生成し, ϵ -貪欲方策で項目を選び, 遷移 $(s_{jt}, i_{jt}, r_{jt}, s_{j,t+1}, \delta_{jt}, \mathcal{B}_{j,t+1})$ を容量 N_D の再生メモリへ格納する. ここで, $\delta_{jt} = \mathbb{1}[t = L]$ は終端指示変数, $\mathcal{B}_{j,t+1}$ は次状態で選択可能な項目集合である. メモリから m 件を一様に抽出し, 目標ネットワーク $Q(s, \cdot; \mathbf{w}^-)$ による目標値

$$y = r + \gamma(1 - \delta) \max_{i' \in \mathcal{B}'} Q(s', i'; \mathbf{w}^-) \quad (4.3)$$

と $Q(s, i; \mathbf{w})$ との二乗誤差の平均を損失とし, Adam [11]で最小化する. 目標ネットワークは τ 回の勾配更新ごとに同期する. 評価時の方策は, 未出題項目の中でQ値が最大の項目を選ぶ貪欲方策である.

Wangらは, Q値が累積情報量の期待値として非負であることを保証する目的で, 全てのパラメータを各更新の際に $w \leftarrow \max(w, 0)$ により非負へ切り詰める. また, 割引率は $\gamma \in \{0.1, 0.3, 0.6, 0.9\}$ から検証により選び, 学習データ量や能力分布の影響も検討している.

4.3 既存手法の問題点

まえがきで述べた問題を, 以下に整理する.

第一に, 全パラメータの非負制約は, Q関数の形を強く制限する. 入力に符号付きスカラー $\hat{\theta}$ であり全パラメータが非負のとき, 式(4.2)の各出力は $\hat{\theta}$ について非負・単調非減少・凸であり, 第1層の折れ点 $-c_{1h}/W_{1h}$ が全て非正であることから, $\hat{\theta} \geq 0$ では厳密に1次関数となる. このとき, 困難度 b_i の項目の価値が $\hat{\theta} \approx b_i$ で最大となる山型の依存を表現できない. なお, Q値の形の制約だけから項目の順位付けが常に不適切になるとは言えないため, この制約の実際の影響は7.3で実測により確かめる.

第二に, 能力推定値 $\hat{\theta}$ は決定過程の状態として不十分である. 同じ $\hat{\theta}$ と同じステップ

数をもつ二つの反応履歴でも、尤度の形が異なれば、同じ項目へ同じ反応をしたときの更新後の推定値は異なる。例えば、識別力を1, 困難度を-1と1とする2項目に1正答1誤答の履歴と、困難度を-2と2とする2項目に同じ反応をした履歴は、いずれも最尤推定値が0であるが、その後に困難度0の項目へ正答したときの推定値はそれぞれ約0.80と約1.11になる。したがって、 $\hat{\theta}$ とステップ数を与えても遷移は一意でなく、Q関数が近似すべき価値は履歴に依存する。出題済み項目を選択から除外するマスクはこの問題を解決しない。マスクはQ関数の入力に含まれないためである。

第三に、報酬の定義に関する問題である。式(4.1)の報酬は、選択時の推定値における情報量であり、MFIの選択規準そのものである。したがって、 $\gamma = 0$ のときQ関数は状態と行動の決定的な関数となり、学習は既知の規準を近似するだけになる。 $\gamma > 0$ では後続の情報量が加わるが、推定値が真の能力から離れているときにその推定値で情報量を評価するというMFIの問題は、報酬の水準で引き継がれる。推定値の不確実性を報酬に反映するには、推定値の1点ではなく、その不確実性を含む量を報酬とする必要がある。

第5章

提案手法

5.1 推定値の不確実性を考慮した状態

提案手法では、ステップ t の状態を、最尤推定値、テストの進行度、事後分散の対数からなる3次元ベクトル

$$s_{jt} = \left(\hat{\theta}_{j,t-1}, \frac{t-1}{L}, \log V_{j,t-1} \right) \quad (5.1)$$

とする． $V_{j,t-1}$ は式(2.6)の事後分散である．最尤推定値は能力の位置を，事後分散は反応履歴が能力について与える不確実性を表す．4.3の例では，二つの履歴の事後分散は異なるため，状態として区別される．なお，状態は反応履歴の全ての情報を保持するわけではなく，尤度の非対称性などは失われる．反応履歴をそのまま状態に含める定式化については付録1で検討する．

5.2 推定値の不確実性を考慮した報酬

報酬を，反応によって事後精度（事後分散の逆数）がどれだけ増えたか

$$r_{jt} = \frac{1}{V_{jt}} - \frac{1}{V_{j,t-1}} \quad (5.2)$$

とする．この報酬には次の性質がある．（1）反応履歴と推定モデルだけから計算できる．（2）割引率を $\gamma = 1$ とすると，エピソードの収益は $\sum_{t=1}^L r_{jt} = 1/V_{jL} - 1/V_{j0}$ と

伸縮し、テスト終了時の事後精度に一致する。したがって、 $\gamma = 1$ の下での収益の期待値の最大化は、最終的な事後精度の期待値 $E[1/V_{jL}]$ の最大化である。なお、逆数の期待値と期待値の逆数は一致しないため、これは事後分散の期待値 $E[V_{jL}]$ の最小化とは同値でない。また、 $\gamma < 1$ では途中のステップの精度増分にも重みが置かれ、最終ステップだけを目的とする定式化ではない。(3) 報酬は推定値の有界性による移動を含まない。反応が予想外であれば事後分散は増え得るため、報酬は負にもなる。これに対し、参照能力値に対する推定誤差の減少量 $(\hat{\theta}_{j,t-1} - \tilde{\theta}_j)^2 - (\hat{\theta}_{jt} - \tilde{\theta}_j)^2$ のような報酬は、収益が同様に伸縮する一方で、式(2.5)の半分移動を含む推定値の変動を直接に反映する。(4) 事後分散の対数減少量 $\log V_{j,t-1} - \log V_{jt}$ は、収益がテスト終了時の事後精度の対数に一致する同様の性質をもつが、その大きさは蓄積した精度に反比例してステップとともに減少する。式(5.2)と対数減少量の値の大きさは7.4で実測して示し、これらの報酬との比較は7.1で行う。

$\gamma = 0$ のとき、Q関数は状態と行動を与えたときの式(5.2)の条件付き期待値、すなわち1ステップ先の期待事後精度増分を近似する。MEPVが1ステップ先の期待事後分散を推定モデルの下で候補項目ごとに数値積分で求めるのに対し、提案手法は、1ステップ先の期待事後精度増分を候補項目ごとの期待値計算の代わりに実際の反応から学習する。ただし、状態に含める事後分散の計算には2.3の格子上の事後分布を用いるため、学習したQ関数が置き換えるのは候補項目ごとの期待値計算であり、格子上の事後分布の計算ではない。 $\gamma > 0$ では、後続の選択を含む複数ステップの精度増分を考慮する。なお、逆数の期待値と期待値の逆数は一致しないため、 $\gamma = 0$ の場合でも提案手法の目的はMEPVの目的と同一ではなく、両者の選択は必ずしも一致しない。

5.3 制約と学習

提案手法では、Q関数のパラメータに非負制約を課さない。式(5.2)の報酬は負にもなり得るため非負制約には根拠がなく、制約を課さなければ4.3で述べた形の制限も生じない。学習は4.2の手順に従い、 M 人の受験者を並列に進行させ、 M 人分の遷移を格納するごとに1回の勾配更新を行う。勾配はノルムが10を超える場合に10へ縮小する。

探索率は、累積受験者数 n と学習受験者数 N に対して

$$\varepsilon(n) = \varepsilon_s + \min\left(1, \frac{n}{\rho N}\right) (\varepsilon_e - \varepsilon_s) \quad (5.3)$$

により線形に減少させる．一定の受験者数 N_{int} ごとに、固定した検証用受験者 N_{val} 人に貪欲方策でテストを実施し、式(5.2)の収益 $1/V_{jL} - 1/V_{j0}$ の平均を検証得点として算出し、学習終了後に検証得点が最大であった時点のパラメータを最終的なQ関数とする．検証得点は反応履歴と推定モデルだけから計算できる．

5.4 実際の反応からの学習と推定モデルへの依存

MFI, FIWL, MPWI, MEPVは、推定モデルとその項目パラメータが正しいという仮定の下で情報量や事後分布を計算する項目選択規則である．実際の運用では、項目パラメータは有限の反応データから推定した値であり、反応過程には推測や不注意など推定モデルに含まれない成分がある．このとき、これらの項目選択規則が計算する期待情報量や期待事後分散は、データ生成モデルの下での値と異なる．

提案手法のQ関数は、状態と行動を与えたときの報酬の条件付き期待値を、学習中にデータ生成モデルと相互作用して得た反応から学習する．報酬の式(5.2)は推定モデルで計算されるが、その期待値はデータ生成モデルに従う反応の分布の下で評価される．したがって、推定モデルがデータ生成モデルと異なる場合でも、提案手法が学習するのは「その項目を出題したときに推定モデルの下で実際に生じる事後精度の増分」の期待値であり、解析的な項目選択規則が計算する「推定モデルの下で生じるはずの増分」とは異なる．この差は、受験者の反応から学習するという強化学習の動機 [7]が精度の改善へ結びつく経路であり、7.5でこの経路の有無を実験により確かめる．

この経路には留意点がある．推定モデルで計算した事後精度は実際の推定誤差そのものではないため、その期待値を正しく学んでも、推定モデルの誤りによる推定量の偏りは残る．提案手法が改善するのは項目の選び方であり、推定量の偏りではない．また、推定モデルがデータ生成モデルと一致する場合には、提案手法が学習する期待値は推定モデルの下で計算できる量であり、この経路による改善は生じない．ただし、

5.2で述べたとおり提案手法の目的はMEPVの目的と同一ではないため、この場合の両者の精度の関係は7の実験により確かめる。なお、本研究の学習はデータ生成モデルとの相互作用を仮定している。固定された過去の記録だけから学習する場合には、記録にない行動の価値の外挿という別の問題 [12]が生じるが、パラメータ推定に用いた反応データのように全項目への反応をもつ記録から学習する場合については付録1で検討する。

第6章

シミュレーション実験

6.1 実験設定

項目バンクは1種類とし、 $I = 500$ 項目の識別力を平均1.2、標準偏差0.25の正規分布から正の値が得られるまで再抽出して生成し、困難度を $N(0, 1)$ から生成した。評価用の受験者は反復ごとに $J = 2000$ 人とし、真の能力を $N(0, 1)$ から生成した。テスト長は $L = 40$ とし、能力推定値の初期値 $\hat{\theta}_{j0}$ は一様分布 $U(-0.5, 0.5)$ から生成した。最尤推定の探索範囲は $[\theta_{\min}, \theta_{\max}] = [-4, 4]$ 、二分法の反復回数は40回、事後分布の格子点数は $G = 81$ とした。シミュレーションにおける反応は、各受験者・各ステップについて一様乱数 $\xi_{jt} \sim U(0, 1)$ をテストの開始前に生成しておき、 $u_{jt} = \mathbb{I}[\xi_{jt} \leq P_{ijt}(\theta_j)]$ として定めた。 $\hat{\theta}_{j0}$ と ξ_{jt} は評価用の乱数種のみで決まるため、同じ乱数種で評価した異なる項目選択規則は、同一の受験者と同一の乱数に直面する。これは共通乱数法による分散削減であり、項目選択規則間の差を選択方策の差として読むためのものである。実験は、項目バンクを固定したまま、評価用受験者、評価用の反応乱数、DQNの初期化・学習・検証に用いる乱数を反復ごとに変えて3回反復した。バンク、評価用受験者、学習用受験者、検証用受験者、反応乱数は、いずれも乱数種と用途識別子の組から独立に生成した乱数列を用い、用途間で乱数列が重ならないようにした。報酬と割引率の感度分析、状態表現の比較、及び要因分解は設計の選択を目的とする探索的な実験であり、反復1から3の乱数種で行った。主結果と推定モデルがデータ生成モデルと異な

る場合の比較は、選択した設計を評価する確証的な実験であり、探索に用いなかった反復4から6の乱数種で行った。

比較する項目選択規則を表6.1に示す。MFI, FIWL, MPWI, MEPVは3の項目選択規則である。このうちMEPVは、1ステップ先の期待事後分散を推定モデルの下で数値積分により最小化する規則であり、提案手法が事後分布に基づく解析的な項目選択規則にどこまで近づくかを検証する直接の比較対象である。既存手法は、4.1の定式化に基づくDQNであり、Wangらの論文本文の記述に従い、報酬に式(4.1)、状態に $\hat{\theta}$ のみ、全パラメータの非負制約、隠れ層の幅50と30、学習受験者1000人の逐次学習、再生メモリ容量1000、ミニバッチ128、目標ネットワークの同期間隔40、定数 $\epsilon = 0.1$ 、検証間隔50人、検証用受験者200人を用いた。割引率は、Wangらが検証により選んだ候補のうち最小の0.1に固定した。本文の記述と異なる点は、項目反応モデルを3パラメータロジスティックモデルから2PLMへ、バンクを複数から単一へ簡略化したこと、Q関数の選択の規準を提案手法と同じ検証得点（当該条件の報酬の収益）としたこと、及び遷移ごとの終端判定と出題済み項目の除外を全ての条件で共通に用いたことである。したがって、既存手法の条件は先行研究の設定に基づく条件であり、公刊結果の再現ではない。

提案手法は、5の定式化に基づき、状態を式(5.1)、報酬を式(5.2)、制約なし、隠れ層の幅64と64、学習受験者 $N = 20000$ 人、並列数 $M = 32$ 、再生メモリ容量 $N_D = 50000$ 、ミニバッチ $m = 128$ 、同期間隔 $\tau = 500$ 、学習率 10^{-3} 、探索率 $(\epsilon_s, \epsilon_e, \rho) = (1, 0.05, 0.5)$ 、検証間隔 $N_{\text{int}} = 2000$ 人、検証用受験者 $N_{\text{val}} = 500$ 人とした。割引率は、7.1の感度分析に基づいて $\gamma = 0.5$ とした。各DQN条件の検証得点には当該条件の報酬の収益を用いた。

評価指標は、ステップ t の推定値 $\hat{\theta}_{jt}$ と真の能力 θ_j から計算するRMSEである。

$$\text{RMSE}_t = \sqrt{\frac{1}{J} \sum_{j=1}^J (\hat{\theta}_{jt} - \theta_j)^2} \quad (6.1)$$

項目選択規則間の比較は、同じ反復の同じ受験者に対するRMSEの対応のある差により行い、3反復にわたる差の平均と範囲を報告する。反復数が3であるため統計的検定

表6.1: 比較する項目選択規則

名称	項目選択規則	備考
MFI	式(3.1)	
FIWL	式(3.2)	尤度重み
MPWI	式(3.3)	事後重み
MEPV	式(3.4)	1ステップ先の期待事後分散
既存	DQN, 報酬 式(4.1)	先行研究の本文の設定
提案	DQN, 式(5.1), 式(5.2)	制約なし

は行わず，差の符号が3反復で一致するかどうかを併せて示す．

更に，参考値として，受験者 j の真の能力において情報量が大きい順に L 項目を選んだときの総情報量 $\mathcal{I}_j^*$ から

$$\text{RMSE}^\dagger = \sqrt{\frac{1}{J} \sum_{j=1}^J \frac{1}{\mathcal{I}_j^*}} \quad (6.2)$$

を算出する．これは，真の能力を知る項目選択規則が L 項目で得る情報量に対する不偏推定量の漸近分散から導いた参照値であり，有界な推定量の有限標本のRMSEに対する下限ではない．実際，個々の反復では実測のRMSEがこの値を下回ることがある．本論文では，この値を各項目選択規則の精度を位置付けるための目安として用い，改善の可能性を否定する根拠には用いない．

第7章

主結果

実験結果を表7.1に示す．表7.1は，各ステップにおけるRMSEの3反復にわたる平均を項目選択規則ごとに示したものであり，最右列は使用した項目数の反復平均である．表では，各ステップの最良値を太字で示している．

表7.1から，次のことがわかる．第一に，ステップ40のRMSEは，既存手法を除く全ての項目選択規則で0.218から0.220の範囲にあり，式(6.2)の参照値0.215に近い．すなわち，40項目の時点では項目選択規則間の差は小さく，差はテスト序盤から中盤に現れる．第二に，情報量に基づく項目選択規則の中では，事前分布を用いるMPWIとMEPVがステップ5でMFIを下回り，MFIとの対応差はいずれも -0.017 （MEPVの範囲 -0.024 から -0.009 ）で3反復の全てで負である．ステップ10では平均 -0.005 と -0.004 であるが反復により符号が変わり，ステップ20以降はMFIと0.002以内の差である．MPWIとMEPVの対応差は全てのステップで平均の絶対値が0.001以下であり，本設定では両者はほぼ同じ項目を選ぶ．事前分布を用いないFIWLはステップ1から5でMFIを上回り（ステップ5で $+0.017$ ，3反復の全てで正），ステップ10以降はMFIとの平均差が最大でも0.007である．

第三に，既存手法は全てのステップで3反復の全てでMFIより大きく，ステップ40の対応差は $+0.039$ （範囲 $+0.035$ から $+0.043$ ）である．使用項目数は72とMFIの202の3分の1程度にとどまる．本研究の設定では，既存手法はMFIを上回らない．

表7.1: 各ステップにおけるRMSE（反復4から6の平均）

項目選択規則	ステップ							項目数
	1	3	5	10	20	30	40	
MFI	1.257	0.765	0.613	0.428	0.300	0.249	0.218	202
FIWL	1.396	0.796	0.629	0.435	0.301	0.251	0.220	198
MPWI	1.285	0.771	0.596	0.423	0.301	0.249	0.220	189
MEPV	1.285	0.771	0.596	0.423	0.302	0.249	0.220	187
既存	1.282	0.857	0.695	0.472	0.340	0.286	0.258	72
提案	1.285	0.780	0.596	0.420	0.302	0.250	0.220	168

第四に、提案手法は、ステップ5でMFIを下回り、対応差は -0.017 （範囲 -0.021 から -0.015 ，MFIの0.613の約3%に相当）と3反復の全てで負である．ステップ10では平均 -0.008 （範囲 -0.025 から $+0.001$ ）であり，ステップ20と40ではMFIと同等である（ステップ40の対応差 $+0.001$ ，範囲 -0.002 から $+0.003$ ）．既存手法に対しては，ステップ40で0.038小さく，使用項目数も168と多い．一方，ステップ1と3では提案手法はMFIより大きく（対応差 $+0.027$ と $+0.015$ ，3反復の全てで正），この区間ではMPWIとMEPVも同様である．テスト開始直後の推定値は式(2.5)の半分移動で決まる部分が大きく，事後分布に基づく項目選択規則の利点はステップ5以降に現れる．MEPVとの比較では，提案手法との対応差はステップ5から40のいずれでも平均の絶対値が0.004以下（ステップ10で -0.004 ，範囲 -0.011 から $+0.001$ ）で反復により符号が変わる．すなわち，提案手法は，1ステップ先の事後分布のモーメントを候補項目ごとに数値積分で求めるMEPVと同等の精度を，候補項目ごとの期待値計算の代わりに学習により達成している．

以上の結果から，推定モデルがデータ生成モデルと一致する場合には，提案手法がテスト序盤でMFIを上回り，事後分布に基づく解析的な項目選択規則と同等の精度を学習により達成することが確認できた．

7.1 報酬関数と割引率の感度分析

提案手法の状態と学習設定の下で、報酬を式(5.2)、事後分散の対数減少量 $\log V_{j,t-1} - \log V_{jt}$ 、参照能力値における情報量 $\mathcal{I}_{i_{jt}}(\tilde{\theta}_j)$ 、式(4.1)、反応後の推定値における情報量 $\mathcal{I}_{i_{jt}}(\hat{\theta}_{jt})$ 、参照能力値に対する推定誤差の減少量 $(\hat{\theta}_{j,t-1} - \tilde{\theta}_j)^2 - (\hat{\theta}_{jt} - \tilde{\theta}_j)^2$ 、及び参照能力値に対する負の二乗誤差 $-(\hat{\theta}_{jt} - \tilde{\theta}_j)^2$ の7種類、割引率を $\gamma \in \{0, 0.5, 0.9, 1\}$ の4水準とした計28条件を、反復1から3で実施した。いずれの報酬も反応記録だけから計算でき、参照能力値を用いる三つの報酬はエピソードの終了後に割り当てる。各条件の検証得点には当該条件の報酬の収益を用いた。

実験結果を表7.2に示す。表7.2は、ステップ5, 10, 20, 40におけるRMSEの3反復にわたる平均を報酬と割引率の組合せごとに示したものであり、最右列は使用した項目数の反復平均である。表では、各ステップの最良値を太字で示している。

表7.2から、次のことがわかる。第一に、提案する式(5.2)の報酬は、 $\gamma = 0$ と $\gamma = 0.5$ においてステップ5と10でMFIを下回る。 $\gamma = 0$ のMFIに対する対応差は、ステップ5で平均 -0.028 （範囲 -0.033 から -0.024 ）、ステップ10で平均 -0.012 （範囲 -0.022 から -0.003 ）であり、いずれも3反復の全てで負である。ステップ20ではMFIと同等であり、ステップ40では平均 $+0.003$ （範囲 $+0.0002$ から $+0.005$ ）と3反復の全てでMFIをわずかに上回る。 $\gamma = 0.5$ も同様であり、 $\gamma = 0$ との差は全てのステップで平均の絶対値が0.006以下で反復により符号が変わる。一方、 $\gamma = 0.9$ と $\gamma = 1$ では全てのステップで精度が低下し、ステップ5では0.665と0.718である。本研究では $\gamma = 0.5$ を採用したが、 $\gamma = 0$ との差は認められず、割引率は0から0.5の範囲で同等、0.9以上で劣化する。なお、この選択は反復1から3の結果に基づくものであり、7の反復4から6における評価とは独立である。

第二に、事後分散の対数減少量を報酬とした場合は、ステップ5と10では式(5.2)と同程度であるが、ステップ40では0.231から0.239と劣り、 $\gamma = 1$ ではステップ5の反復間の標準偏差が0.434に達する。この報酬の大きさは7.4で示すようにステップとともに減少するため、終盤の学習信号が相対的に弱くなるという5.2の見込みと整合する。た

表7.2: 報酬と割引率に対するRMSEの感度（反復1から3の平均）

報酬	γ	ステップ				項目数
		5	10	20	40	
提案手法（式(5.2)）	0	0.594	0.416	0.300	0.223	170
	0.5	0.600	0.419	0.300	0.222	167
	0.9	0.665	0.451	0.311	0.223	158
	1	0.718	0.483	0.337	0.238	156
対数分散減少	0	0.598	0.418	0.303	0.231	159
	0.5	0.611	0.426	0.309	0.232	169
	0.9	0.692	0.457	0.324	0.239	157
	1	1.197	0.567	0.369	0.265	138
参照能力値FI	0	0.598	0.421	0.301	0.221	193
	0.5	0.608	0.421	0.301	0.220	180
	0.9	0.664	0.449	0.310	0.222	166
	1	0.657	0.438	0.315	0.231	158
既存手法（式(4.1)）	0	0.626	0.427	0.300	0.217	199
	0.5	0.631	0.428	0.303	0.220	184
	0.9	0.672	0.452	0.310	0.222	175
	1	0.657	0.454	0.317	0.230	178
反応後推定値FI	0	0.609	0.422	0.300	0.219	194
	0.5	0.618	0.426	0.300	0.222	187
	0.9	0.707	0.469	0.315	0.227	172
	1	0.663	0.451	0.317	0.231	168
参照誤差減少	0	0.790	0.591	0.455	0.334	73
	0.5	0.915	0.659	0.461	0.333	83
	0.9	1.277	0.813	0.514	0.356	99
	1	1.695	1.252	0.840	0.459	125
参照負二乗誤差	0	0.803	0.599	0.452	0.339	88
	0.5	0.783	0.598	0.451	0.329	110
	0.9	0.746	0.555	0.391	0.291	169
	1	0.640	0.485	0.374	0.285	146

だし、本実験はこの機序を直接に測定したものではない。

第三に、参照能力値における情報量を報酬とした場合は、 $\gamma = 0$ においてステップ5と10でMFIを下回り（対応差 -0.025 と -0.008 ，3反復の全てで負），ステップ40では0.221と式(5.2)と同程度である．この報酬はエピソードの終了後にしか割り当てられ

表7.3: 状態表現に対するRMSE（反復1から3の平均）

状態	ステップ				項目数
	5	10	20	40	
A	0.608	0.422	0.300	0.221	182
B	0.609	0.420	0.303	0.222	171
C	0.600	0.419	0.300	0.222	167

ないが，その学習の結果は提案する報酬と同等である．一方，選択時の推定値における情報量を報酬とする式(4.1)は， $\gamma = 0$ においてステップ5で3反復の全てでMFIをわずかに上回り（平均+0.004），ステップ40では3反復の全てでMFIをわずかに下回る（平均−0.003）ものの，使用項目数を含めてMFIとほぼ同じ挙動を示す．これは，4.3で述べたとおり，この報酬の下でDQNがMFIを模倣することを実測で確認したものである．反応後の推定値における情報量を報酬とした場合も同様である．

第四に，参照能力値に対する推定誤差に基づく二つの報酬は，割引率によらず他の報酬より大きく劣り，ステップ40のRMSEは0.285から0.459とMFIより30%から109%大きく，使用項目数は73から169に減る．これらの報酬は式(2.5)の半分移動を含む推定値の変動を直接に反映するため，同じ状態と行動に対する値の変動が情報量型や事後精度型の報酬より大きい．なお，情報量型と事後精度型の報酬では $\gamma \geq 0.9$ で一様に劣化したが，負の二乗誤差では $\gamma = 1$ が最良であり，割引率の影響は報酬に依存する．以上の結果から，反応記録から計算できる報酬の中では式(5.2)と参照能力値における情報量が同程度に有効であり，割引率は0から0.5の範囲で同等で0.9以上で劣化することが確認できた．

7.2 状態表現の比較

提案手法の報酬と学習設定の下で，状態を $\hat{\theta}$ のみ（状態A）， $\hat{\theta}$ と進行度（状態B），式(5.1)（状態C）の三通りとした条件を，反復1から3で実施した．

実験結果を表7.3に示す．表7.3は，ステップ5，10，20，40におけるRMSEの3反復にわたる平均を状態表現ごとに示したものである．

表7.3から、式(5.1)の状態Cがステップ5と10で最も小さいRMSEを示すことがわかる。ステップ5では、推定値だけの状態Aと進行度を加えた状態Bは、状態Cに対してそれぞれ+0.008（範囲+0.002から+0.018）と+0.009（範囲+0.002から+0.018）大きく、いずれも3反復の全てで正である。ステップ10以降では三つの状態の差は0.003以下であり、反復により符号が変わる。すなわち、提案する報酬の下では、事後分散を状態に含めることはテスト序盤の精度に寄与するが、その効果は小さく、中盤以降には認められない。状態Aでも提案する報酬と学習設定を用いればステップ5と10でMFIを下回る（対応差−0.015と−0.007、3反復の全てで負）ことから、序盤の改善の大部分は報酬と学習設定によるものであり、状態の拡張はそれに小さな改善を加えるにとどまる。4.3で述べた状態の非マルコフ性は、本設定の推定精度に対しては限定的な影響しかもたない。

7.3 既存手法から提案手法への要因分解

既存手法と提案手法は、(1) 非負制約の有無、(2) 状態表現 ($\hat{\theta}$ のみ／式(5.1))、(3) 報酬（式(4.1)／式(5.2))、(4) 割引率、(5) 学習設定群（隠れ層の幅、学習受験者数、並列数、再生メモリ容量、同期間隔、探索率の推移、検証間隔）の五つの要因で異なる。要因(5)は複数の設定をまとめて切り替えるものであり、個々の設定の効果を分離するものではない。特に、学習受験者数は1000人から20000人へ増えるが、並列数が1から32へ増えるため勾配更新の回数はむしろ減る点に留意されたい。どの要因が決定的かを同定するため、既存手法から一つの要因だけを提案手法の値へ変えた5条件と、提案手法から一つの要因だけを既存手法の値へ戻した5条件を、両端の2条件と併せて計12条件について、反復1から3で実施した。

実験結果を表7.4に示す。表7.4は、ステップ5, 10, 20, 40におけるRMSEの3反復にわたる平均と使用項目数の反復平均を条件ごとに示したものである。条件名の「+」は既存手法へ当該要因の変更を加えたこと、「−」は提案手法から当該要因を既存手法の値へ戻したことを表す。

表7.4から、次のことがわかる。第一に、既存手法から非負制約だけを外すと、ス

表7.4: 既存手法と提案手法の要因分解（反復1から3の平均）

条件	ステップ				項目数
	5	10	20	40	
MFI	0.623	0.429	0.301	0.220	199
既存	0.748	0.498	0.353	0.263	70
既存+非負制約	0.621	0.427	0.304	0.221	176
既存+状態表現	0.754	0.499	0.349	0.261	69
既存+報酬	0.763	0.496	0.358	0.272	64
既存+割引率	0.693	0.474	0.343	0.261	75
既存+学習設定群	0.737	0.476	0.338	0.258	72
提案	0.600	0.419	0.300	0.222	167
提案-非負制約	0.701	0.451	0.322	0.246	79
提案-状態表現	0.608	0.422	0.300	0.221	182
提案-報酬	0.631	0.428	0.303	0.220	184
提案-割引率	0.599	0.416	0.302	0.224	171
提案-学習設定群	0.675	0.451	0.322	0.241	187

ステップ40のRMSEは0.263から0.221へ約16%減少し（対応差 -0.042 ，範囲 -0.051 から -0.034 ，3反復の全てで負），ステップ5では0.748から0.621へ減少して（ -0.127 ，3反復の全てで負）MFIと同水準になる．使用項目数も70から176へ増える．学習設定群だけを提案手法の値へ変えた場合はステップ40で -0.005 （3反復の全てで負）と小さく，状態表現と割引率だけの変更では差の符号が反復により変わる．報酬だけを式(5.2)へ変えと，ステップ40で $+0.009$ （3反復の全てで正）と悪化する．第二に，提案手法から非負制約を戻すと，ステップ40で $+0.024$ （範囲 $+0.017$ から $+0.028$ ），ステップ5で $+0.100$ と3反復の全てで悪化し，使用項目数は79へ減る．学習設定群を戻した場合も，ステップ40で $+0.019$ ，ステップ5で $+0.075$ と3反復の全てで悪化する．報酬を式(4.1)へ戻すと，ステップ5で $+0.031$ （範囲 $+0.020$ から $+0.044$ ，3反復の全てで正）悪化するが，ステップ40では差がない．状態表現を推定値だけへ戻す影響はステップ5の $+0.008$ （3反復の全てで正）にとどまり，割引率を0.1へ戻す影響はステップ40で $+0.002$ である．

以上から，非負制約の除去は既存手法を改善し提案手法から外すと精度を損なう決定的な要因であり，学習設定群がそれに次ぐ．提案する報酬の寄与はテスト序盤に限

られ、しかも既存手法の他の設定の下ではむしろ精度を損なうため、その効果は非負制約の除去と学習設定の変更を前提として初めて現れる。状態表現と割引率の影響は小さい。なお、勾配更新の回数は既存側の設定で39873回、提案側の設定で24997回であり、学習設定群の効果は更新回数の増加によるものではない。学習設定群は複数の設定をまとめたものであるため、並列に進める受験者数の増加による遷移の多様化、再生メモリの拡大、探索率の減少方策のいずれが効いているかは本実験では分離できない。

7.4 選択される項目の分析

提案手法が序盤にどのような項目を選んでいるかを、MFIとMEPVと比較する。提案手法を反復4の乱数種で1回学習し、三つの項目選択規則を同じ2000人の評価用受験者に対して共通乱数で実行した。各受験者・各ステップについて、選択された項目の識別力と困難度、選択時の推定値、真の能力、及び選択時点の反応履歴が全問正答または全問誤答であるかを記録し、ステップごとに次の量を算出した。(1) 選択された困難度を選択時の推定値へ回帰したときの傾き。(2) 選択された困難度と真の能力の差の絶対値の平均。(3) 選択された識別力の平均。(4) 選択時点で全問正答または全問誤答であった受験者の割合と、その受験者が当該ステップの総二乗誤差に占める割合。併せて、MFIの経路に沿って式(5.2)の報酬と事後分散の対数減少量をステップごとに計算し、その平均、標準偏差、負となる割合を求めた。

四つの量のステップ1から20までの推移を図7.1に示す。図7.1の各パネルは、横軸がステップ、縦軸が上記の(1)から(4)の量を表し、各線は項目選択規則を表す(Proposedは提案手法)。図7.1から、次のことがわかる。第一に、ステップ1では、提案手法とMEPVは推定値によらず同じ項目を選び(回帰の傾き0.00)、その識別力は1.87とMFIが選ぶ項目の1.80より大きい。ステップ2でも両者は同じ項目を選んでおり、識別力の平均は2.01とMFIの1.96より大きい。第二に、選択された困難度の推定値への回帰の傾きは、ステップ2から7で提案手法とMEPVがMFIより小さく(ステップ3で0.66と0.65に対しMFIは0.80)、ステップ10で0.78とMFIの0.86に近づく。このた




図7.1: 選択された項目の特性のステップごとの推移

め、全問正答または全問誤答により推定値が大きく移動するステップ3では、選択された困難度と真の能力の距離は提案手法が0.58, MEPVが0.59とMFIの0.65より小さい。ただし、ステップ10以降ではこの距離に項目選択規則間の差はない。第三に、選択時点で全問正答または全問誤答であった受験者の割合は、ステップ5で提案手法が7.2%, MEPVが6.5%とMFIの2.2%より多く、その受験者が総二乗誤差に占める割合も20%と18%でMFIの7%より大きい。しかし、ステップ5のRMSEは提案手法が0.607, MEPVが0.598とMFIの0.622より小さい。したがって、提案手法とMEPVは、識別力の高い項目を選ぶことで極端な反応パターンをMFIより多く生じさせる一方、それ以外の受験者の推定誤差をより小さくしており、この二つの効果の差し引きで序盤の精度が決まっていると考えられる。以上の三点で提案手法の挙動はMEPVとほぼ一致しており、提案手法がMEPVと同等の精度を示すことと整合する。

報酬の尺度については、MFIの経路に沿って計算した式(5.2)の報酬の平均はステップ1で0.48, ステップ5で0.58, ステップ40で0.47と, テストを通じて同程度であり, 受験者間の標準偏差は0.06から0.19である. 負の値をとる割合はステップ40で0.15%, 他のステップでは0であり, 事後分散が増える反応は稀である. これに対し, 事後分散の対数減少量の平均はステップ1の0.39からステップ40の0.02へ減少し, 5.2で述べた尺度の縮小が確認できる.

7.5 推定モデルとデータ生成モデルが異なる場合の比較

5.4の経路を確かめるため, データ生成モデルが推定モデルと異なる設定で比較した. データ生成モデルは, 6.1と同じ項目バンクの識別力と困難度に, 擬似推測パラメータ $c_i \sim U(0.1, 0.3)$ を加えた3パラメータロジスティックモデル

$$P_i(\theta) = c_i + \frac{1 - c_i}{1 + \exp\{-a_i(\theta - b_i)\}} \quad (7.1)$$

とした. 推定モデルは2PLMのままとし, 全ての項目選択規則と式(2.5)の推定量は真の識別力と困難度(a_i, b_i)を用いる. すなわち, 項目パラメータに誤差はなく, 推測という推定モデルに含まれない反応の成分だけが両モデルの差である. 擬似推測パラメータは反復ごとに引き直し, 評価用受験者の反応は式(7.1)から生成した. 提案手法は, 学習時のシミュレーションにおける反応の生成と検証得点の算出にも式(7.1)を用いた. これは, 運用中の受験者と相互作用しながら学習する状況に対応する. 各条件を反復4から6で実施した.

実験結果を表7.5に示す. 表7.5は, 各ステップにおける真の能力に対するRMSEの3反復にわたる平均を項目選択規則ごとに示したものであり, 最右列は使用した項目数の反復平均である. 表では, ステップ3以降の各ステップの最良値を太字で示している.

表7.5から, 次のことがわかる. 第一に, 推測を含むデータ生成モデルの下では, 推定モデルの下で最適な項目選択規則を含む全ての項目選択規則のRMSEが7より大きく, ステップ40でMFIは0.218から0.492へ, MEPVは0.220から0.471へ増加する. 2PLM

表7.5: 推測を含むデータ生成モデルの下での各ステップにおけるRMSE（反復4から6の平均）

項目選択規則	ステップ							項目数
	1	3	5	10	20	30	40	
MFI	1.371	1.051	0.947	0.751	0.585	0.523	0.492	196
FIWL	1.481	1.157	1.008	0.781	0.610	0.544	0.508	193
MPWI	1.370	1.006	0.825	0.651	0.537	0.494	0.473	184
MEPV	1.370	1.006	0.825	0.657	0.536	0.492	0.471	184
提案	1.370	1.015	0.812	0.639	0.531	0.487	0.468	156

の推定量は推測による正答を能力の高さとして解釈するため、どの項目選択規則で項目を選んでも推定量の偏りは残る。その中で、事後分布に基づくMPWIとMEPVはステップ3以降の全てのステップでMFIを下回り、MEPVのMFIに対する対応差はステップ5で -0.122 、ステップ40で -0.021 （範囲 -0.025 から -0.015 ）と3反復の全てで負である。推定モデルがデータ生成モデルと一致する場合には終盤で消えていた事後分布に基づく項目選択規則の利点は、推測の下では終盤まで残る。

第二に、データ生成モデルから得た反応で学習した提案手法は、ステップ3以降の全てのステップでMFIを下回り（ステップ5で -0.135 、ステップ40で -0.024 、いずれも3反復の全てで負、ステップ40ではMFIの0.492の約5%に相当）、MEPVに対してもステップ10で -0.018 （範囲 -0.031 から -0.002 ）、ステップ30で -0.005 、ステップ40で -0.003 （範囲 -0.004 から -0.0001 、MEPVの0.471の約1%に相当）と3反復の全てで下回る。ステップ5と20では平均 -0.013 と -0.005 であるが反復により符号が変わる。推定モデルがデータ生成モデルと一致する場合（表7.1）には提案手法とMEPVは同等であったのに対し、推測の下では提案手法がMEPVを小さいながら一貫して上回る。これは、5.4で述べた経路、すなわち提案手法が学習する期待精度増分が推測を含む実際の反応の分布の下で評価されることが、本設定で実際に働くことを示唆する。ただし、提案手法が改善するのは項目の選び方だけであり、推定量の偏りは残るため、改善の大きさは限定的である。以上の結果から、推定モデルとデータ生成モデルが異なる場合には、実際の反応から学習した提案手法が解析的な項目選択規則を上回ることが確認できた。

表7.6: 1受験者・1ステップあたりの選択時間 (μs)

項目選択規則	受験者1人ずつ			2000人一括		
	$I=500$	2000	8000	500	2000	8000
MFI	7.1	14	45	2.5	10	44
FIWL	36	40	59	8.8	11	19
MPWI	36	40	59	8.8	11	19
MEPV	53	79	390	11	20	57
提案	49	72	90	8.8	9.8	14

7.5.1 推論時の選択時間

各項目選択規則が1受験者の1ステップの項目選択に要する時間を計測した。10項目の反応履歴をもつ受験者に対し、受験者1人ずつ選択する場合と2000人を一括して選択する場合について、項目数 I を500, 2000, 8000としたバンクで、1回の選択に要した壁時計時間を受験者数で割った値を求めた。提案手法は学習済みと同じ構造のネットワークを用い、状態の事後分散の計算を含めて計測した。計測はPyTorchとNumPyの線形代数ライブラリの双方でスレッド数を1に固定して行った。

計測結果を表7.6に示す。表7.6は、1受験者・1ステップあたりの選択時間をマイクロ秒で示したものである。

表7.6から、次のことがわかる。第一に、いずれの項目選択規則も1受験者・1ステップの選択に要する時間は最大でも0.4msであり、本実験の規模では、事後分布に基づく項目選択規則を含めて実時間の運用に支障はない。格子上の事後分布の計算は行列積として一括で行えるため、1次元の能力に対しては計算量の問題は大きくない。第二に、項目数への依存は項目選択規則によって異なる。受験者1人ずつの選択では、項目数を500から8000へ増やすとMEPVは53 μs から390 μs へ約7倍になるのに対し、提案手法は49 μs から90 μs へ1.8倍にとどまり、MPWIは36 μs から59 μs である。項目数が小さい場合には、提案手法はネットワークの順伝播の固定的な費用のためMPWIより遅く、MEPVと同程度である。第三に、2000人を一括して選択する場合には、提案手法は項目数8000で14 μs と最も速く、MEPVの57 μs の4分の1程度である。以上から、提案手法

の計算上の利点は、大規模なバンクにおける選択時間の伸びが1ステップ先の事後分散や事後精度を評価する項目選択規則より小さい点にあり、バンクが小さい場合の速度の利点は認められない。なお、多次元的能力を扱う場合には格子の点数が次元に対して指数的に増えるため事後分布に基づく項目選択規則の計算量が急増する。多次元の推定モデルの下での精度と選択時間は付録2で報告する。

7.6 考察

実験結果を踏まえ、提案手法の位置付けと適用範囲を整理する。第一に、推定モデルがデータ生成モデルと一致する場合、提案手法は事後分布に基づく解析的な項目選択規則と同等の精度にとどまり、それを上回らなかった (7)。提案手法の目的はMEPVの目的と同一ではなく (5.2)、両者の選択が常に一致するわけではないが、本実験の設定では精度は同程度であった。推定モデルが正しければ、提案手法が学習する式(5.2)の報酬の条件付き期待値は推定モデルの下で計算できる量であり (5.4)、この場合に学習によって得られるのはその量の近似である。したがって、項目数の大きいバンクにおける選択時間の利点 (7.5.1) を除けば、この場合に学習を用いる積極的な理由はない。第二に、データ生成モデルが推測を含む場合には、実際の反応から学習した提案手法が解析的な項目選択規則を小さいながら一貫して上回った (7.5)。この優位は、報酬の期待値が実際の反応の分布の下で評価されることによるものであり、推定モデルの誤りによる推定量の偏りそのものは解消しない。したがって、提案手法の利点は、推定モデルがデータ生成モデルと異なる状況で項目の選び方を改善する点にあり、その大きさは両モデルの差の種類と程度に依存する。第三に、提案手法が学習するのは、学習集団の能力分布と探索方策の下での報酬の期待値であり、得られる方策は学習集団に依存する。また、状態は反応履歴の要約であって履歴そのものではなく、尤度の非対称性などは失われる。反応履歴を状態に含めても精度が改善しないことは付録1で確かめたが、本論文の実験は、2PLM、単一の項目バンク、固定長のテスト、及び式 (2.5) の推定量という条件の下での比較であり、結果をこの条件の外へそのまま一般化することはできない点に留意されたい。

7.7 まとめ

本論文では、深層Q学習に基づくCATの項目選択法について、全パラメータの非負制約、能力推定値だけを用いる状態、及び選択時の推定値における情報量という報酬に関する既存手法の問題点を整理し、最尤推定値、テストの進行度、事後分散からなる状態と、事後精度の増分という推定値の不確実性を考慮した報酬に基づく項目選択法を提案した。また、2PLMに基づくシミュレーション実験により、提案手法がテスト序盤でMFIを上回り、事後分布に基づく解析的な項目選択規則と同等の精度を、候補項目ごとの期待値計算を学習したQ関数で置き換えて達成すること、既存手法の劣化の決定的な要因が非負制約であり学習設定がそれに次ぐこと、反応履歴から計算できる報酬の中では事後精度の増分が有効で割引率は0から0.5で同等であること、及び事後分散を状態に含めることの寄与はテスト序盤に限られ小さいことを示した。更に、データ生成モデルが推測を含む一方で推定モデルが2PLMである場合には、実際の反応から学習した提案手法が解析的な項目選択規則を小さいながら一貫して上回ることを示した。付録では、反応履歴を状態に含める定式化が精度を改善しないこと、2次元のデータ生成モデルの下で学習した方策が解析的な項目選択規則を上回るのは項目パラメータの推定誤差が出題次元の偏りを生む場合に限られること、及び推定モデルとデータ生成モデルが一致する多次元の項目反応モデルの下では学習した方策が厳密な近視眼的な項目選択規則を上回らないことを、再現に必要な設定とともに報告した。

なお、本研究では推定モデルを2PLMに限り、単一のバンクと固定長のテストのみを扱ったが、複数のバンク、可変長の終了規則、露出制御や内容制約を伴う設定への拡張は今後の課題としたい。また、推定モデルとデータ生成モデルの差は推測に限り、学習はデータ生成モデルとの相互作用を仮定したが、他の差の下での挙動や、固定された過去の記録だけから学習する場合への拡張も今後の課題としたい。

謝辞

本研究を行うにあたり，親切にご指導を頂いた宇都雅輝准教授，植野真臣教授に厚く御礼を申し上げます．ゼミ発表中のコメントが大変励みになりました．また，プログラミングまわりの相談に際して岡野さん，柴田さんには重要な助言を賜りました．お陰で問題点を修正することができました．研究室の皆様に深く感謝申し上げます．

参考文献

- [1] H. Wainer, ed., Computerized Adaptive Testing: A Primer, 2nd edition, Lawrence Erlbaum Associates, 2000.
- [2] F.M. Lord, Applications of Item Response Theory to Practical Testing Problems, Lawrence Erlbaum Associates, 1980.
- [3] H.-H. Chang and Z. Ying, “A global information approach to computerized adaptive testing,” *Applied Psychological Measurement*, vol.20, no.3, pp.213–229, 1996.
- [4] W.J.J. Veerkamp and M.P.F. Berger, “Some new item selection criteria for adaptive testing,” *Journal of Educational and Behavioral Statistics*, vol.22, no.2, pp.203–226, 1997.
- [5] W.J. van derLinden, “Bayesian item selection criteria for adaptive testing,” *Psychometrika*, vol.63, no.2, pp.201–216, 1998.
- [6] A. Ghosh and A. Lan, “BOBCAT: Bilevel optimization-based computerized adaptive testing,” *Proceedings of the 30th International Joint Conference on Artificial Intelligence*, pp.2410–2417, 2021.
- [7] P. Wang, H. Liu, and M. Xu, “An adaptive testing item selection strategy via a deep reinforcement learning approach,” *Behavior Research Methods*, vol.56, pp.8695–8714, 2024.
- [8] V. Mnih, K. Kavukcuoglu, D. Silver, A.A. Rusu, J. Veness, M.G. Bellemare, A. Graves, M. Riedmiller, A.K. Fidjeland, G. Ostrovski, S. Petersen, C. Beat-

- tie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, and D. Hassabis, “Human-level control through deep reinforcement learning,” *Nature*, vol.518, pp.529–533, 2015.
- [9] B.G. Dodd, “The effect of item selection procedure and stepsize on computerized adaptive attitude measurement using the rating scale model,” *Applied Psychological Measurement*, vol.14, no.4, pp.355–366, 1990.
- [10] R.J. Owen, “A bayesian sequential procedure for quantal response in the context of adaptive mental testing,” *Journal of the American Statistical Association*, vol.70, no.350, pp.351–356, 1975.
- [11] D.P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” *Proceedings of the 3rd International Conference on Learning Representations* (arXiv:1412.6980), 2015.
- [12] S. Fujimoto, D. Meger, and D. Precup, “Off-policy deep reinforcement learning without exploration,” *Proceedings of the 36th International Conference on Machine Learning*, pp.2052–2062, 2019.